# Informatische Grundlagen für Chemie und Biologie

lvo Hofacker
ivo@tbi.univie.ac.at

Institut für Theoretische Chemie Universität Wien

October 16, 2015

# Geschichtliches

700 BC	Abakus
300 BC	Euklidischer Algorithmus :
	Effiziente Bestimmung des ggT
500	Erfindung Dezimalsystem in Indien
800	Muhammed ibn Musa abu Djafar al-Chwarismi
	Einführung der Null zu den Arabischen Zahlen
	"Liber Algorithmi" - Rechenverfahren mit Dezimalzahlen
	für Kaufleute und Testamentsvollstrecker
	Aus seinem Namen und griechischem "arithmos" (Zahl)
	stammt der Begriff <b>Algorithmus</b>
1202	Leonardo v. Pisa (Fibonacci)
	"Liber abbaci" - Einführung in dezimales Rechnen
1574	Adam Riese
	Rechenbuch mit mathematischen Algorithmen
	Erste Logarithmentafeln werden algorithmisch berechne
	Nepersche Rechenstäbe zum Multiplizieren
1623	Rechenmaschine von Schickard
	Addition, Subtraktion mit 6 stelligen Zahlen

# Geschichtliches

1641	Blaise Pascal
	Addiermaschine mit 8 Stellen
1674	Gottfried Wilhelm Leibniz
	Rechenmaschine für die 4 Grundrechenarten
1774	Philipp Matthäus Hahn
	Erste zuverlässig arbeitende mechanische Rechenmaschine
1805	Joseph Marie Jacquard
	Webstuhl mit fester Programmsteuerung
1823	Charles Babbage
	"Difference engine"
1886	Herman Hollerith
	Erfindung der Lochkarte
1934	Konrad Zuse
	programmierbarer Relaisrechner auf Basis des Dualsystems
1936	Church-Turing These (zur Berechenbarkeit)
	"Die Klasse der turing-berechenbaren Funktionen stimmt mit der
	Klasse der intuitiv berechenbaren Funktionen überein."
1941	Konrad Zuse
	Elektromechanischer programmgesteuerter Rechner Z3

#### Geschichtliches

1944 Howard Aiken Mark I, sequentieller elektromech. Rechner 1946 Mauchly/Eckert ENIAC, Röhrentechnologie 1949 Edsac von Wilkes Erster Rechner mit gespeichertem Programm 1954 Rechner der 1. Generation (IBM 650, USA) 1957 Fortran (formula translator) auf Rechnern der 2. Generation (Transistoren, Ferritspeicher) 1960 COBOL, ALGOL 1962 BASIC 1971 Rechner der 3. Generation Integrierte Schaltungen, Mikroprozessoren, PASCAL 1973 Programmiersprache C 1980 Modula, Ada, PCs, Rechnernetze, Workstations 1986 Laptops, Parallel-Rechner 1990 optische Platten, Internet, World WideWeb

### Teilgebiete der Informatik

#### Theoretische Informatik

- Berechenbarkeit und Komplexität
- Automaten und Formale Sprachen

#### Praktische Informatik

- Algorithmen und Datenstrukturen
- Programmiermethoden und -sprachen
- Betriebssystem und Compilerbau
- Datenbanken

# Angewandte Informatik


- Informationssysteme und KI
- Modellierung und Simulation
- Anwendungen in Wirtschaft, Wissenschaft, etc.

### Technische Informatik

- Rechnernetze und -organisation
- Prozessoren und andere Schaltwerke
- Mikroprogrammierung

Algorithmen und Datenstrukturen

# Lösen von Problemen mit Hilfe eines Computers



"Berechnungsvorschrift, die genau definiert, wie aus Eingabedaten Ausgabedaten durch systematische Anwendung von Elementaroperationen in endlich vielen Schritten ermittelt werden."

### Folgende Bedingungen müssen erfüllt werden:

- Korrektheit
- Allgemeingültigkeit (Abstrahierung, löst eine Problemklasse)
- Ausführbarkeit (Jeder Schritt muss durch eine Rechenmaschine ausführbar sein)
- Determiniertheit (gleiche Eingabe → gleiches Ergebnis)
- Finitheit (statisch und dynamisch)
- Terminiertheit (endlich viele Schritte)

#### Ein Algorithmus sollte verständlich und effizient sein!

#### Beschreibungssprache:

- Natürliche Sprache zur Kommunikation von Ideen oft ausreichend
- Diagramme
   Darstellung des Kontrollflusses durch Ablaufpläne,
   Struktogramme, etc.
- Pseudo Code Mischung aus Konstrukten einer Programmiersprache und Prosa
- Programmiersprache
   Präzise, Garantiert die Ausführbarkeit auf einer Maschine

## Berechnungenbarkeit

"Eine Funktion ist berechenbar wenn es einen Algorithmus gibt, der sie berechnet!"


Ansätze zur Präzisierung des Berechenbarkeitsbegriffs:

- Turing-Berechenbarkeit
- While-Berechenbarkeit
- Goto-Berechenbarkeit
- . . .

Diese Präzisierungen beschreiben die selbe Klasse an Funktionen

→ Churchsche These:

"Die Klasse der turing-berechenbaren Funktionen stimmt mit der Klasse der intuitiv berechenbaren Funktionen überein." **Die Turing Maschine** 



- Die Turing Maschine hat eine endliche Anzahl von Zuständen q<sub>s</sub>, q<sub>h</sub>, q<sub>1</sub>, ..., q<sub>n</sub>.
- Das **Programm** ist eine Tabelle mit Anweisungen der Form  $\langle q_i, s_i, s_k, m, q_l \rangle$ .
- Ein Band, das als Speicher sowie als Inpu/Output fungiert.
- Ein Lese-Schreib-Kopf, der die aktuelle Position des Bandes lesen und schreiben kann.

### Programmausführung auf einer Turing Maschine

- Lese das Symbol and der aktuellen Position des Bandes
- ② Ändere den Zustand der Maschine von  $q_i$  to  $q_i$ .
- 3 Schreibe das Symbol  $s_i$ .
- 4 Bewege den Lese-Schreib Kopf in Richtung m.

```
 \begin{array}{c} \langle q_1, 1, 0, R, q_2 \rangle \\ \langle q_1, 0, 0, R, q_1 \rangle \\ \langle q_2, 1, 1, R, q_2 \rangle \\ \langle q_2, 0, 0, R, q_3 \rangle \\ \langle q_3, 1, 1, R, q_3 \rangle \\ \langle q_3, 1, 1, R, q_4 \rangle \\ \langle q_4, 1, 1, L, q_4 \rangle \\ \langle q_4, 0, 0, L, q_5 \rangle \\ \langle q_5, 1, 1, L, q_5 \rangle \end{array}
```

 $\langle q_5, 0, -, -, halt \rangle$ 

# While-Berechnungenbarkeit

- Variablen:  $x_0, x_1, x_2, \ldots$ , Konstanten: 0, 1, 2, ...
- Operatoren: + −, Trennsymbole; ←
- Schlüsselwörter: WHILE DO END

#### Syntax:

- **1** Eine Wertzuweisung  $x_i \leftarrow x_i \pm c$  ist ein While-Programm
- 2 Wenn  $P_1$  und  $P_2$  While-Programme sind dann auch  $P_1$ ;  $P_2$
- **3** Falls P ein While-Programm ist dann auch WHILE  $x_i \neq 0$  DO P END
- Nur durch 1.-3. beschriebene Programme sind While-Programme

#### Semantik:

- **1** Wertzuweisung :  $x_i$  wird der Wert von  $x_i \pm c$  zugewiesen
- Sequenz: Zuerst wird P<sub>1</sub>, dann P<sub>2</sub> ausgeführt
- **3** Schleife: P wird solange ausgefürt bis  $x_i = 0$  gilt. Test erfolgt vor Ausführung von P

# While-Berechnungenbarkeit

```
Beispiel:
```

(Multiplikation mit Eingabe  $x_1$ ,  $x_2$  und Ausgabe  $x_0$ )

WHILE 
$$x_1 \neq 0$$
 DO  $x_3 \leftarrow x_2$ 

WHILE  $x_3 \neq 0$  DO

 $x_0 \leftarrow x_0 + 1;$  $x_3 \leftarrow x_3 - 1$ 

END;  $x_1 \leftarrow x_1 - 1$ 

Abkürzungen:

IF  $x \neq 0$  THEN  $P_1$  ELSE  $P_2$  END

an Stelle von

**END** 

 $x_1 \leftarrow 1: x_2 \leftarrow x:$ 

WHILE  $x_2 \neq 0$  DO  $P_1$ ;  $x_2 \leftarrow 0$ ;  $x_1 \leftarrow 0$  END;

WHILE  $x_1 \neq 0$  DO  $P_2$ ;  $x_1 \leftarrow 0$  END

### Goto-Berechnungenbarkeit

Sequenzen von Markern  $M_i$  und Anweisungen  $A_i$  der Form  $M_1: A_1; M_2: A_2; ...; M_k: A_k$ 

### Anweisungen

- Wertzuweisung:  $x_i \leftarrow x_i \pm c$
- unbedingter Sprung: GOTO M<sub>i</sub> (damit wird A<sub>i</sub> als n\u00e4chstes ausgef\u00fchrt)
- bedingter Sprung: IF  $x_i = c$  THEN GOTO  $M_i$
- Stopanweisung: HALT

While-Schleifen lassen mit Goto's simulieren:

WHILE 
$$x_i \neq 0$$
 DO  $P$  END wird zu

$$M_1$$
: IF  $x_i = 0$  THEN GOTO  $M_2$ ;  $P$ ; GOTO  $M_1$ ;  $M_2$ : . . .

GOTO-Programme sind schwer verstehbar und damit kaum verifizierbar.

#### **Ein Nicht-Algorithmus**

# Wir machen Eierspeis

- Schlage die Eier in eine Schüssel
- Fuege Salz und Pfeffer geriebenen K\u00e4se und etwas Milch hinzu und r\u00fcre gut durch
- Schneide Schinken in Streifen oder kleine Quadrate und brate ihn in einer Pfanne mit etwas Öl an
- Gib den Inhalt der Schüssel in die Pfanne
- Schieb die stockende Masse solange in der Pfanne umher bis sie die richtige Konsistenz hat
- Nimm die Eierspeis vom Herd und bestreue sie mit Paprikapulver und Petersilie oder Schnittlauch


#### **Euklidischer Algorithmus**

Finde den grössten gemeinsamen Teiler zweier ganzer Zahlen m, n

- 1 Wenn *m* kleiner als *n*, vertausche Werte von *m* und *n*
- Dividiere m durch n, nenne den Rest r
- Wenn r gleich 0 ist, so gib n aus und terminiere
- Wenn r nicht gleich 0 ist, so weise m den Wert von n zu und n den von r
- Gehe zu 2.

# **Euklidischer Algorithmus**

Finde den grössten gemeinsamen Teiler zweier ganzer Zahlen m, n



#### **Euklidischer Algorithmus**

**Algorithm 1** Finde den grössten gemeinsamen Teiler gcd(n,m) zweier ganzer Zahlen m, n

```
if m=0 then

return n

end if

while m \neq 0 do

if n > m then

n \leftarrow n - m

else

m \leftarrow m - n

end if

end while

return n
```

(while-Schleife und Zuhilfenahme von primitiven Operationen)

#### **Euklidischer Algorithmus**

**Algorithm 2** Finde den grössten gemeinsamen Teiler  $\gcd(n,m)$  zweier ganzer Zahlen m, n

```
while m \neq 0 do

if n < m then

t \leftarrow m

m \leftarrow n

n \leftarrow t

end if

t \leftarrow m

m \leftarrow n \mod m

n \leftarrow t

end while

return n
```

(while-Schleife und Zuhilfenahme von komplizierten Operationen)

### **Euklidischer Algorithmus**

**Algorithm 3** Finde den grössten gemeinsamen Teiler  $\gcd(n,m)$  zweier ganzer Zahlen m, n

```
if n < m then
    swap n, m
end if
if m = 0 then
    return n
else
    return gcd(m, n mod m)
end if</pre>
```

(Rekursion und Zuhilfenahme von komplizierten Operationen)

# **Euklidischer Algorithmus**

# Nochmal in Kurzfassung:

Solange m > 0:

Wenn n > m, Vertausche n und m.

Subtrahiere *n* von *m*.

n ist der Größte Gemeinsame Teiler

### Zu Zeigen ist:

- Korrektheit
- Termination
- Komplexität

# **Euklidischer Algorithmus**

#### Korrektheit

Gegeben m > 0 und n > 0, sei g = gcd(n, m)

- Wenn m = n dann m = n = gcd(n), m wird auf 0 gesetzt und n zurückgeliefert, eindeutig korrekt.
- Wenn m > n, dann  $m = p \cdot g$  und  $n = q \cdot g$  wobei p und q teilerfremd sind. Behauptung: gcd(m-n,n) = g, und damit  $m-n = p \cdot g q \cdot g = (p-q) \cdot g$ . Es muss also gelten, dass (p-q) und q teilerfremd sind. Wenn **nicht**, dann  $p-q = a \cdot c$  und  $q = b \cdot c$  für a, b, c > 1. Daraus folgt aber  $p = q + a \cdot c = b \cdot c + a \cdot c = (a+b) \cdot c$ . Weil  $q = b \cdot c$  können damit p und q nicht teilerfremd sein,

#### Kontradiktion!

Also sind (p - q) und q teilerfremd und gcd(m - n, n) = gcd(m, n).

**3** Wenn n < m werden n und m vertauscht, so dass  $m \ge n$ . Dieser Fall ist bereits abgehandelt.

# **Euklidischer Algorithmus**

# Terminierung

Beim Start jedes Schleifendurchlaufs (Iteration) ist entweder n > m oder m > n.

- Wenn  $m \ge n$  wird m durch m n ersetzt. Damit ist m kleiner als zuvor und nicht negativ
- Wenn n > m werden m und n vertauscht und im n\u00e4chsten Schritt gilt wieder 1.

Damit wird das Maximum  $\max(m, n)$  in jedem Schritt entweder kleiner oder bleibt für eine Iteration gleich.

Das widerum kann aber nicht für immer so weiter gehen, da m und n ganze Zahlen sind und irgendwann ein unteres Ende erreicht werden muss, nämlich genau dann wenn m=0 und n=g. Also terminiert der Algorithmus.

Es gilt festzustellen wie effizient ein bestimmter Algorithmus ist

#### Effizienzmaße:

- Speicherbedarf
- Laufzeit
- weitere Problemabhängige Parameter, z.B. Anzahl an Vergleichsoperationen bei Suchverfahren oder Anzahl der Bewegung von Datensätzen

#### Analysestrategien:

- experimentelle Bestimmung schlecht geeignet da Abhängig von Programmiersprache, Compiler und Computer
- asymptotische Analyse
   Wie schnell steigt der Aufwand mit steigender Problemgrösse?
   Betrachtung des Worst-case, Best-case und Average-case
   Szenarios

### **Euklidischer Algorithmus**

#### Komplexität

#### Zeit

Eine Iteration braucht konstante Zeit, ist aber abhängig davon ob m > n oder nicht.

Wenn m = n, dann gibt es nur eine Iteration (**best-case**) Wenn n = 1, dann erfolgen m Iterationen (**worst-case**) **average-case** ist schwierig zu analysieren

#### Speicher

Der Speicherbedarf ist konstant, da nur drei ganze Zahlen gespeichert werden müssen.

Beispiel zur asymptotischen Analyse (Mittelwert über n Zahlen in Liste L:

	Kosten	Wie oft?			
1: initialize list L with values	<i>C</i> <sub>1</sub>	1			
2: initialize variable <i>sum</i> with 0	<i>C</i> <sub>2</sub>	1			
3: initialize variable <i>length</i> with 0	<i>C</i> <sub>3</sub>	1			
4: for each value <i>v</i> of List <i>L</i>	<i>C</i> <sub>4</sub>	n			
5: do					
6: add $v$ to $sum$	<i>C</i> <sub>5</sub>	n			
7: add 1 to length	<i>C</i> <sub>6</sub>	n			
8: end					
9: set mean equal to $sum$ divided by $length$ $c_7$ 1					

Laufzeitfunktion T(n):

$$T(n) = c_1 + c_2 + c_3 + n \cdot c_4 + n \cdot c_5 + n \cdot c_6 + c_7$$

Aymptotisch steigt die Laufzeit linear, der Algorithmus ist  $\mathcal{O}(n)$ 

Die Landau Symbole: Θ-,  $\mathcal{O}$ - und  $\Omega$ -Notation

Sei g(n) eine Schrankenfunktion, dann ist eine

Obere Schranke

$$\mathcal{O}(g(n)) = \{ f(n) | (\exists c, n_0 > 0), (\forall n \ge n_0) : 0 \le f(n) \le cg(n) \}$$

Untere Schranke

$$\Omega(g(n)) = \{f(n) | (\exists c, n_0 > 0), (\forall n \ge n_0) : 0 \le cg(n) \le f(n) \}$$

Genaue Wachstumsrate

$$\Theta(g(n)) = 
\{f(n)|(\exists c_1, c_2, n_0 > 0), (\forall n \ge n_0) : 0 \le c_1 g(n) \le f(n) \le c_2 g(n)\}$$

Beispiel:  $\mathcal{O}(n^2)$  ist die "Menge aller Funktionen, die nicht schneller als quadratisch wachsen".

Regeln für  $\Theta$ -,  $\mathcal{O}$ - und  $\Omega$ -Notationen


- Ignoriere konstante Faktoren  $\mathcal{O}(c \cdot f(n)) = \mathcal{O}(f(n))$ z.B.  $\mathcal{O}(20 \cdot n^3) = \mathcal{O}(n^3)$
- ② Ignoriere kleine Terme Wenn a < b dann  $\mathcal{O}(a+b) = \mathcal{O}(b)$ z.B.  $\mathcal{O}(n^2 + n) = \mathcal{O}(n^2)$
- ③ Für *obere* Schranke gilt: Wenn a < b dann ist ein  $\mathcal{O}(a)$ - auch ein  $\mathcal{O}(b)$ -Algorithmus z.B. Ein  $\mathcal{O}(n)$ - ist auch ein  $\mathcal{O}(n^2)$ -Algorithmus

# Aber nicht anders herum!

- ② Ignoriere addition von konstanten Termen Da n und log n größer als jede Konstante k sind, gilt z.B.  $\mathcal{O}(\log n + k) = \mathcal{O}(\log n)$
- § Vereinfachung durch geschachtelte Anwendung der oben genannten Regeln z.B. ist ein  $\mathcal{O}(n \cdot \log n + n)$ -Algorithmus ein  $\mathcal{O}(n \cdot (\log n + 1))$ -Algorithmus, also ein  $\mathcal{O}(n \cdot \log n)$ -Algorithmus


Wichtige Schrankenfunktionen

Notation	Name	Beispiel
O(1)	konstant	Berechnen ob eine Zahl gerade oder
		ungerade ist
$\mathcal{O}(\log n)$	logarithmisch	Eine Zahl in einer sortierten Liste
		mittels Binärer Suche suchen
$\mathcal{O}(n)$	linear	Eine Zahl in einer unsortierten Liste suchen
$\mathcal{O}(n \log n)$	loglinear	Eine Liste mittels Quicksort sortieren
$\mathcal{O}(n^2)$	quadratisch	Eine Liste mittels Insertionsort sortieren
$\mathcal{O}(10^n)$	exponentiell	Travelling Salesman Problem
		(Dynamic Programming)
$\mathcal{O}(n!)$	faktoriell	Travelling Salesman Problem
. ,		(Brute Force)



# Komplexitätsklassen

- Messung der Komplexität am Ressourcenverbrauch (Laufzeit, Speicherbedarf)
- Klassifizierung aller lösbaren Probleme (Abgrenzung von effizient lösbaren von schwierigen Problemen)



### Komplexitätsklassen

- Für Probleme der Klasse P existieren effiziente Algorithmen, die das Problem in polynomialer Laufzeit lösen.
   Es genügt also zu zeigen, dass deren Komplexität O(n<sup>k</sup>) für eine Konstante k ist.
- Für Probleme der Klasse NP lässt sich die Richtigkeit einer Lösung in polynomialer Laufzeit prüfen.
- Probleme, die nicht in P sind, gelten als hart. Für praktische Zwecke sind sie oft nicht lösbar, da der Aufwand schneller als polynomial ansteigt. Viele interessante Probleme liegen in NP. Es gibt jedoch nichtdeterministische Algorithmen die diese Probleme in polynomialem Zeitaufwand lösen.
- NP-schwer (NP-hard): Ein Entscheidungsproblem L heißt NP-schwer genau dann, wenn alle Probleme aus der Klasse NP polynomiell auf L reduzierbar sind.
- NP-vollständig (NP-complete): Ein Entscheidungsproblem L heißt NP-vollständig genau dann, wenn L in der Klasse NP liegt und L NP-schwer ist.

### Komplexitätsklassen

### NP vollständige Probleme

- Alle gleich schwierig da sie aufeinander reduzierbar sind
- Sollte für eines ein Polynomialzeit Algorithmus gefunden werden, wären automatisch alle NP Probleme in Polynomalzeit lösbar In diesem Fall wäre P = NP.
- Da kein polynomialer Algorithmen für NP-vollständige Probleme bekannt ist gilt wahrscheinlich  $P \neq NP$ .

Allerdings ist auch noch kein Beweis für  $P \neq NP$  gelungen.

# Beispiele

- Travelling Salesman: Ein Vertreter, dessen Bezirk eine bestimmte Anzahl von Städten umfaßt, beginnt seine Reise stets von seiner Basis aus, besucht jede Stadt genau einmal und kehrt dann zur Basis zurück. Um die Reisekosten zu minimieren, hat er eine Tabelle der gegenseitigem Entfernungen der Städte seines Bezirks zusammengestellt.
- Rucksackproblem: Gegeben sind eine Anzahl von Waren verschiedener Größe und von unterschiedlichem Wert. Man fülle den Rucksack so, daß man Waren von maximalem Gesamtwert transportiert.

#### Sortieren

- Sortieren ist eines der häufigsten Probleme
- Vielzahl von Algorithmen
- Erlaubt schnelle Suche in sortierten Daten

#### **Problemstellung:**

Gegeben: Datensatz  $s_1, s_2, \ldots, s_n$  mit Schlüsseln  $k_1, k_2, \ldots, k_n$ , und eine Ordnungsrelation "<" auf den Schlüsseln.

Gesucht: Permutation

$$\pi: 1, 2, \ldots, n \to 1, 2, \ldots, n$$

die die Schlüssel in Aufsteigende Reihenfolge bringt:

$$k_{\pi(1)} \leq k_{\pi(2)} \leq \ldots \leq k_{\pi(n)}$$

Der Einfachheit halber, nehmen wir im folgenden immer an das Listen von Zahlen sortiert werden.

#### Insertion-Sort

Idee: 2 Listen mit sortierten und unsortierten Zahlen; nehme eine Zahl der unsortierten Liste füge sie in sortierte Liste ein.

```
Algorithm 4 Insertion-Sort(A)
```

```
Input: List of numbers in array A (A[1], A[2], ..., A[n])
Output: Sorted list in A

for j = 2 to n do

k = A[j]
i = j - 1
while i > 0 and A[i] > k do

A[i + 1] = A[i]
i = i - 1
end while
A[i + 1] = k
end for
```

 $A[1] \dots A[j]$  is sorted, rest still unsorted

#### Selection-Sort

Idee: Finde kleinste Zahl, bringe sie an den Anfang der unsortierten Liste

```
Algorithm 5 Selektion-Sort(A)
```

```
Input: List of numbers in array A (A[1], A[2], ..., A[n])
Output: Sorted list in A
  for j = 1 to n do
    minpos = i
    for i = j + 1 to n do
       if A[i] < A[minps] then
         minpos = i
       end if
       if minpos > j then
         swap A[minpos] and A[i]
       end if
    end for
  end for
```

#### **Bubble-Sort**

Idee: Vertausche benachbarte Zahlen falls Reihenfolge falsch

Wiederhole bis Liste sortiert ist

# **Algorithm 6** Bubble-Sort(A)

```
Input: List of numbers in array A (A[1], A[2], ..., A[n])

Output: Sorted list in A

for i = 1 to n do

for j = 1 to n - i do

if A[j] > A[j + 1] then

swap A[j], A[j + 1]

end if

end for
end for
```

Rechenaufwand offensichtlich in  $\mathcal{O}(n^2)$ Beschleunigung um 50% durch vorzeitigen Abbruch, falls keine Vertauschung passiert ist.